Исполняемые файлы, динамическая загрузка

Лекция 17

Кодирование инструкций

- Каждая инструкция однозначно представляется в бинарном виде
- На x86/x64 инструкция кодируется последовательностью от 1 до 16 байт
- Требования к кодированию:
 - Однозначность декодирования
 - Компактность

Кодирование относительно ІР

- Инструкция jmp:
 8048098:eb 17 jmp 80480b1
- Занимает 2 байта, адрес после нее: 804809А
- В инструкции кодируется смещение относительно ЕІР: 17
- 804809a + 17 = 80480b1
- На x86 так кодируются инструкции call, jmp, jCC
- На x64 существует специальный режим адресации: RIP-relative:
 - mov L1(%rip), %rax

Абсолютное кодирование

• Загрузка адреса в памяти на регистр:

```
80480a2: b9 b5 80 04 08 mov $0x80480b5,%ecx 80480b5: 48 65 6c 6c 00 asciz "Hell"
```

- Загрузка значения глобальной переменной в регистр
- В закодированной инструкции записывается абсолютный адрес в памяти

Загрузка программы в память

- Программа единое целое, взаимное расположение кода внутри секций и секций друг относительно друга не изменяется
 - Смещения в относительных переходах и работе с памятью настраиваются компоновщиком и при загрузке в память не изменяются
- При компоновке фиксируется адрес, по которому программа должна размещаться в памяти, абсолютные адреса в программе настраиваются относительно него
 - ELF Linux x86 по умолчанию: 0x804800
 - Можно изменить с помощью -WI,-Ttext-segment=ADDR

Позиционная зависимость

- Если программа неработоспособна при загрузке по адресу, отличному от прописанного в исполняемом файле программа **позиционно зависима**
- Позиционно-независимый код (PIC position independent code) сохраняет работоспособность при загрузке с любого адреса в памяти
- Полезен:
 - В динамических библиотеках
 - Динамическая кодогенерация

Исполняемый файл (executable)

- Файл, основное содержимое (payload) которого программа для процессора
- После загрузки в память и первоначальной настройки исполняется непосредственно процессором, не требует программы-"интерпретатора"
- Тексты программ на python, bash; .jar-файлы (байт-код java); .net MSIL не будем считать исполняемыми файлами

Native executable files

- У каждой операционной системы свой формат исполняемых файлов:
 - Windows: PE (portable executable)
 - MacOS, iOS: Mach-O (Mach Object)
 - Unix-like (Linux, *BSD, Solaris): ELF (executable and linkable format)
- Один и тот же формат может использоваться для разных процессоров
- Исполняемый файл специфичен для пары процессор-ОС (платформа)

Portability

- Операционные системы могут поддерживать "чужие" исполняемые файлы, если хост-система работает на том же процессоре.
 - FreeBSD поддерживает возможность запуска ELFфайлов для Linux той же процессорной архитектуры
 - Wine поддержка запуска Windows-приложений на Unix-like системах

Инструменты работы

- Binutils набор утилит для работы с исполняемыми файлами:
 - Objdump отобразить содержимое:
 - objdump -d FILE дизассемблировать
 - objdump -x FILE вывести всю служебную инфу
 - objdump -j SECTION -s FILE вывести содержимое секции SECTION в файле FILE
 - Readelf анализ ELF-файла
 - Nm список "символов" (symbols, т.е. именованных сущностей) в файле
- GDB, IDA PRO, OllyDBG отладчики

ELF

- ELF Executable and Linkable Format
- Применяется на многих Unix-like OS (Linux, *BSD, Solaris, ...)
- Для всех процессоров, на которых эти ОС работают
- Формат: объектных файлов (.о), статических библиотек (.а), динамических библиотек (.so), исполняемых файлов, дампов памяти, модулей ядра ОС (.ko)...

Структура ELF-файла

- Заголовок ELF-файла (magic bytes и структура Elf32_Ehdr)
- Таблица заголовков программы (program headers) структура Elf32_Phdr
- Payload содержимое файла
- Таблица заголовков секций (section headers) структура Elf32_Shdr

(почти) минимальный ELF

- Заголовок файла 52 байта
- 1 запись program header по 32 байта 32
- Исполняемый код 7
- Таблица имен секций 17
- 3 записи секций по 40 байт 120 байт
- Итог: 228 байт.
- Задание получить такой ELF-файл

Program Headers

- Информация о том, как исполняемый файл должен грузиться в память
- LOAD заданная область файла должна быть загружена в память
- LOAD требует выравнивания (align) в 0х1000 (4096 байт) это размер страницы х86/х64 (рассмотрим далее)
- LOAD с флагами 'R E' это сегмент кода
- LOAD с флагами 'RW' это сегмент данных
- Записи Program Headers могут описывать накладывающиеся адреса

Section Headers

- Секция это структурная единица в исполняемом файле
- Секции группируются в сегменты
- Типичные секции:
 - .text, .data, .bss, .rodata
 - .plt procedure linkage table
 - got global offset table
 - got.plt global offset table for PLT

Динамическая компоновка

- Как правило (по умолчанию) программа, загружаемая на выполнение, не содержит в своем файле кода используемых библиотек
- Перед запуском программы требуется подгрузить динамические библиотеки
- Программа-загрузчик (интерпретатор) прописывается в секции .interp файла (для x86 /lib/ld-linux.so.2)
- Операционная система загружает исполняемый файл, загружает требуемый загрузчик и запускает его
- Загрузчик выполняет подгрузку библиотек и передает управление программе

Динамические символы

- Секция .dynsym содержит таблицу динамических символов, то есть имен, требуемых из данного файла или предоставляемых данным файлом
- Секция .rel.dyn содержит таблицу перемещений для переменных, т. е. адреса ячеек памяти, которые должны быть изменены
- Секция .rel.plt содержит таблицу перемещений для внешних функций

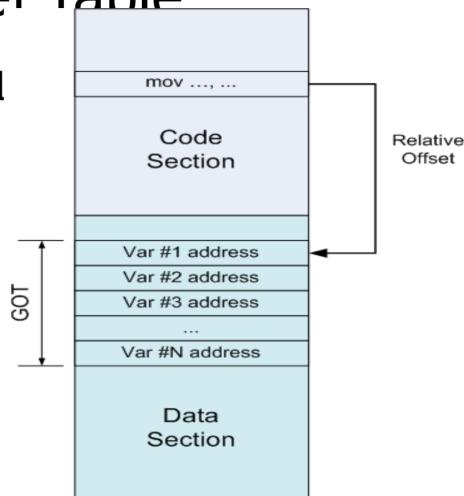
Global Offset Table

- Чтобы не модифицировать код программы, все перемещения находятся в специальных секциях
 - .got для переменных
 - .got.plt для функций
- После работы загрузчика таблица .got содержит абсолютные адреса переменных

Global Offset Table

_GLOBAL_OFFSET_TABI

L@GOT



Использование GOT

- _GLOBAL_OFFSET_TABLE_ это смещение относительно **адреса текущей инструкции** до адреса GOT
- LABEL@GOT это смещение относительно GOT до ячейки памяти, в которой хранится правильный адрес, по которому размещается LABEL

Procedure Linkage Table (PLT)

- В динамически скомпонованных программах часть GOT отводится под хранение адресов функций из динамических библиотек
- Если printf функция из динамической библиотеки, то call printf заменяется на call printf@plt
- printf@plt специальная функция (трамплин) для передачи управления в библиотеку

Procedure linkage table (PLT)

```
080483f0 <dvnlink>:
80483f0: ff 35 04 a0 04 08
                                     pushl
                                            0x804a004
80483f6: ff 25 08 a0 04 08
                                            *0x804a008
                                     jmp
80483fc:
        00 00
                                            %al,(%eax)
                                     add
08048410 <printf@plt>:
        ff 25 10 a0 04 08
8048410:
                                      *0x804a010
                                 jmp
8048416: 68 08 00 00 00
                                 push
                                      $0x8
804841b: e9 d0 ff ff ff
                                      80483f0 <dynlink>
                                 jmp
0804a000 < GLOBAL OFFSET TABLE >:
804a000:
              14 9f 04 08
                                 .int
                                      0 \times 8049 f14 < DYNAMIC>
804a004:
              00 00 00 00
                                      0
                                 .int
804a008:
              00 00 00 00
                                 .int
804a00c:
              06 84 04 08
                                 .int 0x8048406
804a010
              16 84 04 08
                                 int 0x8048416
```

Lazy binding

- При первом вызове <printf@plt> управление попадет в динамический загрузчик. В стеке будет передано смещение на дескриптор загружаемой функции
- Динамический загрузчик запишет в GOT адрес функции printf в загруженной динамической библиотеке
- Все последующие вызовы будут передавать управление сразу на printf в динамической библиотеке

Зачем нужны трамплины

- Компилятор и ассемблер не имеют информацию, в каком режиме будет компоноваться программа
 - они всегда генерируют инструкцию CALL FUNC для вызова функции FUNC
 - Компоновщик (linker) при необходимости заменит CALL FUNC на CALL FUNC@PLT и сгенерирует трамплин FUNC@PLT
- Если в Си-коде берется адрес функции, например, &printf, то компоновщик заменяет на &printf@plt без модификации машинного кода
- Позволяют реализовывать ленивое связывание (lazy binding)

Ссылки

- http://eli.theareenplace.net/2011/11/03/position-independent-co de-pic-in-shared-libraries
- https://www.cs.stevens.edu/~jschauma/810/elf.html
- https://ejudge.ru/study/3sem/elf.html

•